

Detekcja anomalii w telemetrii serwerowej

Trzy metody. Jeden zbiór. Protokół ustalony przed wynikami.

Cel i zbiór

Sprawdzenie lokalnego procesu uczenia, kalibracji i oceny detektorów anomalii jako przygotowanie metodyczne do prac B+R. Wykorzystano publiczny SMD: wyłącznie machine-1-2, 38 kanałów i punktowe etykiety anomalii [1]. Poprzedni pilotaż machine-1-1 nie wchodzi do tego porównania.

Metody bez strojenia

Rolling: odchylenie od średniej z poprzednich 60 próbek, normalizowane skalą treningową, maksimum po kanałach. IForest 1D: 38 niezależnych jednozmiennowych lasów, parametry domyślne scikit-learn, seed 42; maksimum score. DAE: PyTorch, 38-32-8-32-38, ReLU, maskowanie 15%, MSE, Adam, 30 epok, batch 256. Jedna ustalona konfiguracja; brak optymalizacji hiperparametrów.

Podział i zamrożenie

Plik treningowy: 18,955 próbek do uczenia i 4,619 do kalibracji. Plik z etykietami: 9,477 na walidację i 14,097 na holdout. Między blokami pozostawiono 120 próbek; pierwsze 60 próbek każdego bloku pominięto w ocenie jako kontekst. Nie losowano okien między zbiorami. Skaler dopasowano na treningu; progi to 99. percentyl score w kalibracji.

Wybrany baseline: Isolation Forest 1D. F1 walidacji: Rolling 0.103, IForest 0.138. Wybór oraz progi zapisano w osobnym commicie przed jednorazowym odczytem holdoutu. Wyniki wszystkich metod raportuje się niezależnie od rankingu testowego.


Wynik końcowego holdoutu

14,037 ocenionych próbek, 9.75 doby, 7 incydentów. Precision, recall i F1 dotyczą incydentów.

Metoda	Precision	Recall	F1	FA / dobę
Średnia ruchoma	0.095	0.857	0.171	5.64
Isolation Forest 1D	0.118	0.286	0.167	1.54
Autoenkoder DAE	0.095	0.857	0.171	5.54

DAE uzyskał wyższe F1 niż baseline wybrany na walidacji: 0.171 wobec 0.167. Dopasował 6 z 7 incydentów przy 5.54 FA/dobę; baseline dopasował 2 z 7 przy 1.54 FA/dobę. Rolling uzyskał F1 0.171: nie wykazano przewagi DAE nad monitoringiem progowym. To obserwacja z jednego bloku, nie dowód przewagi ogólnej ani gotowości wdrożeniowej.

Cały przebieg testowy i detekcje



Kanał 4 (indeks od 0) wybrano przez najwyższą wariancję treningową, przed testem. Czerwone tło: incydenty. Zielone punkty: rzeczywiste przekroczenia progu. Linia przerywana: zamrożony próg. Oś score/prog jest symetrycznie logarytmiczna; pokazano pełny holdout.

Jak liczone są alarmy

Przekroczenia oddalone o nie więcej niż 30 próbek łączono w epizod bez korzystania z etykiet. Dopasowanie jeden-do-jednego wymaga rzeczywistego przekroczenia wewnątrz incydentu; przerwy między alertami nie wypełniano trafieniami. Duplikaty obniżają precision. FA oznacza epizod bez trafienia w jakikolwiek incydent; $FA/dobę = FA / \text{czas całego ocenianego bloku}$. Przeliczenie czasu zakłada regularny interwał 1 min według [2]; CSV nie ma timestampów.

Średnia ruchoma: 6/7 trafień, 63 epizodów, 55 FA, 2 duplikatów; Isolation Forest 1D: 2/7 trafień, 17 epizodów, 15 FA, 0 duplikatów; Autoenkoder DAE: 6/7 trafień, 63 epizodów, 54 FA, 3 duplikatów.

Wnioski i ograniczenia

Udział surowych próbek alarmowych: Średnia ruchoma 0.71%; Isolation Forest 1D 0.58%; Autoenkoder DAE 0.75%. Skuteczność trzeba oceniać razem z obciążeniem alarmami. Wynik nie uzasadnia automatycznego wyboru bardziej złożonej metody.

Publiczny zbiór nie odwzorowuje heterogenicznej telemetrii radiowej. Brak kontrolowanych scenariuszy degradacyjnych. Rozpoznanie służy weryfikacji metodyki i narzędzi, nie walidacji rozwiązania. Jedna maszyna, jeden seed i niewielka liczba incydentów nie pozwalają na wnioski o generalizacji. Ciągłe bloki SMD nie są niezależnymi przebiegami testbedu. Nie badano few-shot, grafów ani diagnostyki przyczynowej. Wyniki bazowe nie rozstrzygają problemu badawczego planowanego projektu.

Odtwarzalność i źródła

Protokół: commit befc8edff39c. Seed 42, CPU, PyTorch 2.14.0; hashe danych, kodu i modelu zapisano w manifest.json oraz freeze.json. Surowe score, alarmy i dopasowania znajdują się w pakiecie. Historia Git dokumentuje kolejność lokalną; nie jest niezależnym znacznikiem czasu.

[1] SMD / OmniAnomaly: github.com/NetManAI/OmniAnomaly, commit 7fb0e0acf89ea49908896bcc9f9e80fcfff6baf4.

[2] Li i in., An Empirical Analysis of Anomaly Detection Methods for Multivariate Time Series, tabela I (interwał SMD).